

Notas de Estudio: Algoritmos Supervisados

Clasificados por Dificultad

Inteligencia Artificial

29 de noviembre de 2025

Introducción

Listado de algoritmos de aprendizaje supervisado ordenados por complejidad. Incluye **usos típicos** y **ejemplos** para repaso rápido.

1. Nivel Básico

Características: Fáciles de implementar, pocos hiperparámetros, interpretables.

Ejemplo de uso: Predicción de precios (Regresión Lineal), detección de spam (Naïve Bayes).

- **Regresión Lineal:** $y = \beta_0 + \beta_1 x_1 + \epsilon$
Aplicación: Predicción de valores continuos (ej. ventas).
- **Regresión Logística:** $P(y = 1) = \frac{1}{1+e^{-(\beta_0+\beta x)}}$
Aplicación: Clasificación binaria (ej. riesgo crediticio).
- **k-NN:** Clasificación por votación de vecinos.
Hiperparámetro clave: Número de vecinos (k).

2. Nivel Intermedio

Características: Requieren fine-tuning, manejan relaciones no lineales.

Ejemplo de uso: Diagnóstico médico (SVM), fraud detection (Random Forest).

- **Árboles de Decisión:** División recursiva por umbrales.
Ventaja: Explicables visualmente (ej. `graphviz`).
- **SVM:** Maximiza el margen entre clases.
Kernel trick: Transforma datos a espacios de mayor dimensión.
- **Random Forest:** Ensemble de árboles con bagging.
Hiperparámetro clave: Número de árboles.

3. Nivel Avanzado

Características: Alto rendimiento, pero complejos de ajustar.

Ejemplo de uso: Competencias de Kaggle (XGBoost), reconocimiento de imágenes (CNN).

- **XGBoost:** Optimización con gradiente y regularización.
Diferencia: Manejo eficiente de datos faltantes.
- **Redes Neuronales:** Backpropagation + optimizadores (Adam, SGD).
Overfitting: Se controla con Dropout y Early Stopping.

Resumen Visual



Flujograma de selección de algoritmos según tipo de problema.